

Aula 1

Reinforcement Learning

Prof. Gian Carlo Brustolin

1

Conversa Inicial

2

Bases para *reinforcement learning*

- Nesta aula introdutória, iniciaremos com conceitos elementares de inteligência artificial (IA) e evoluiremos até o entendimento dos rudimentos de aprendizagem de máquina (ML), interpretação de parâmetros por máquina (DL) e *reinforcement learning* (RL)

3

Bases para *reinforcement learning*

- Conceitos de IA
- Abordagens de IA
- Teoria da aprendizagem e treinamento em ambientes determinísticos
- Treinamento supervisionado x treinamento auto-organizado
- Treinamento por reforço

4

Conceitos de IA

5

- Terminologia
 - Agente inteligente
 - Meio
 - Ação
 - Política e função do agente
 - Estado

6

- **Agente inteligente é tudo o que pode ser considerado “capaz de perceber seu ambiente por meio de sensores e de agir sobre esse ambiente por intermédio de atuadores”** (Norvig, 2013, p. 30)
- ✓ **Agente reativo – ações plenamente determinadas pelo seu criador**
- ✓ **Agente baseado em aprendizagem**

7

- **A ausência de aprendizagem não descaracteriza o agente reativo como inteligente** (Facelli et al., 2021, p. 1)

8

- **Meio é o ambiente externo ao agente. Pode ser:**
- ✓ **Observável – em função da capacidade dos sensores (plenamente ou parcialmente)**
- ✓ **Inobservável – sem sensores, mas segue possível ação**
- ✓ **Determinístico**
- ✓ **Estocástico**

9

- **Ação – atuação do agente sobre o meio**


10

- **Política e função do agente**
- ✓ **Política ou função do agente é uma descrição matemática abstrata**
- ✓ **Programa do agente é uma implementação concreta, executada em um sistema físico**

11

- **Estado designa a relação atual do agente com o meio**

- ✓ **Valor do estado é a avaliação da utilidade de manter-se em dado estado, ou mesmo de escolher mover-se para outro estado**



12

Abordagens de IA

13

Abordagens de IA

- Há técnicas de IA que têm por base o processo mecânico de raciocínio humano
- Outras partem de um algoritmo de enfrentamento do problema, buscando a parametrização matemática das variáveis do problema
- Um terceiro grupo estuda as formas de enfrentamento, pela natureza, dos problemas evolutivos

14

- Simbólica
- ML
- Neurociência computacional
- IA forte x IA fraca

15


IA simbólica

- Uso de algoritmos de solução de problemas dedicados, chamados de *sistemas especialistas* ou *sistemas baseados em conhecimento*
- Projetista cria um *motor de inferência*, algoritmo que toma as decisões baseado em regras *se-então*
- Técnicas de ML podem ser agregadas a estes sistemas, permitindo certa evolução

16

ML

- Técnicas de ML surgiram como incrementos aos métodos clássicos de IA
- Algoritmos de ML são capazes de criar uma árvore de busca ou um conjunto de regras baseado em *datasets* tratados previamente



17

ML

- As técnicas de ML se assemelham a métodos de análise estatística descritiva ou preditiva
- A popularidade desta aproximação cresceu substancialmente com a disponibilidade de bibliotecas de algoritmos
- As técnicas clássicas de ML encontram seu limite justamente na preparação dos *datasets*

18

ML

- **Representation learning** ou **feature learning** (FL) – métodos que permitem à máquina consumir dados naturais e descobrir, então, as representações necessárias para o algoritmo de ML
- **Deep learning** (DL) – evoluções de FL com vários níveis de representação
 - “Pilha” de métodos de FL, obtendo-se, a cada passo na pilha, um nível maior de abstração
 - Redes neurais

19


Neurociência computacional e IA conexionista

- Tentativa de simulação do processo biológico do raciocínio humano
- Entende o raciocínio pela óptica das conexões entre neurônios
 - Boa parte da memória e da capacidade de interpretação racional está ligada às sinapses neurais

20

Neurociência computacional e IA conexionista

- **Peso sináptico** é um parâmetro livre da rede neural e permite *intensificar* ou *deprimir* a conexão entre dois neurônios



21

Neurociência computacional e IA conexionista

- **Modelo neural básico** – 1943 (McCulloch e Pitts)
- Há numerosas topologias de rede neural
- Topologia influencia na qualidade do aprendizado
 - Rede grande – boa memória, mas não generalizará bem
- Uma dezena de neurônios trata problemas matemáticos complexos

22

IA forte x IA fraca

- **Forte** – assemelhar o comportamento do agente inteligente ao humano, capacitando-o a enfrentar ambientes inusitados e a tomar decisões hipoteticamente autônomas
- **Fraca** – dar a cada agente somente a inteligência necessária para enfrentar determinado tipo de problema

23

Teoria da aprendizagem e treinamento em ambientes determinísticos

24

Teoria da aprendizagem e treinamento em ambientes determinísticos

- Treinamento de agentes
- Métodos de treinamento de agentes
- Aprendizagem por correção de erro
- Aprendizagem baseada em memória
- Aprendizagem por árvores de decisão
- Aprendizagem competitiva e hebbiana

25

Treinamento de agentes

- Antigos sistemas especialistas já possuíam, em sua concepção, as informações necessárias para a tomada de decisão
- Redes neurais são sujeitas a treinamento prévio à sua operação
- Modelos de ML aprendem tendo como base conjuntos de dados escolhidos para este fim (*datasets*)

26

Métodos de treinamento de agentes


- Fatores vinculados ao sucesso da aprendizagem computacional:
 - Qual componente deve ser melhorado
 - ✓ Mapeamento de estado/ação; utilidade...
 - Conhecimento prévio do agente
 - Representação dos dados
 - *Feedback* que está disponível para aprendizagem

27

Aprendizagem por correção de erro

- Redes neurais
- Ajustar os parâmetros da rede para que $x(n)$ apresente como saída o valor $y(n)=d(n)$
- Técnica usual para a correção do erro médio da rede é a regra de Widrow-Hoff (ou delta)

28




Fonte: Haykin, 2011, p. 77.

29

Aprendizagem baseada em memória

- “Memorizaremos” vários exemplos de entrada-saída classificados em determinada ordem
- Compararemos o valor de entrada (chamado de *vetor de teste*) com as amostras de memória e tomaremos a decisão “mais próxima”



Fonte: Haykin, 2019, p. 80.

30


Aprendizagem por árvores de decisão

- Idealizada nos sistemas especialistas
- Algoritmos de ML criam a árvore automaticamente, com base em *datasets*
- Algoritmo de árvore – um vetor de entrada encontrará uma saída correspondente, em função de uma série de testes de hipóteses ocorridos no interior da árvore

31

Aprendizagem por árvores de decisão

- É necessário escolher a ordem das perguntas (*atributos*) segundo sua relevância



32

Aprendizagem competitiva e hebbiana

- Utiliza a propriedade de auto-organização estatística dos fenômenos naturais
- Hebb – quando um neurônio N, próximo a P, repetidamente provoca a reação de P, a proximidade físico-química entre estes neurônios cresce, potencializando ainda mais esta reação
- Desta constatação, criou-se uma técnica de treinamento neural que corrige os parâmetros livres da rede conforme a saída de um neurônio se vê estimulada

33

Treinamento supervisionado x treinamento auto-organizado

34

Treinamento supervisionado


- Realizado com base em amostras de entrada/saída validadas por alguém que possua conhecimento do meio
- “Aprendizado com um professor”
- Algoritmo precisa controlar o erro, assim, em algoritmos de ML, separamos parte das amostras para medir a acuidade do treinamento

35

Treinamento supervisionado

- Aprendizagem será supervisionada se a previsão que desejamos que o algoritmo de ML faça está baseada em dados presentes no *dataset*

36



Treinamento auto-organizado

- Há uma regularidade estatística em fenômenos naturais
 - Os dados tendem a auto-organizar-se
 - Em 1976, o prêmio Nobel de química foi concedido a Prigogine pela aguardada comprovação desta tendência
- Os parâmetros livres de uma RNA tenderão, se permitirmos que se alterem por si, a produzir uma rede capaz de compreender, ou generalizar, o processo inicialmente caótico a que ela está sujeita

Treinamento por reforço – RL

- Tipo de aprendizagem em que a evolução do agente é obtida pela análise da reação do meio às suas ações
 - O agente pode ser previamente treinado ou não
- Pode ser entendido como um tipo de treinamento não supervisionado

Treinamento por reforço – RL


- Ambiente estocástico e decisão sequencial
- Modelo decisório de Markov
- Conceito de utilidade e a solução de Bellman
- Ambientes de RL

Ambiente estocástico e decisão sequencial

- Ambientes determinísticos têm boa estabilidade e previsibilidade
 - Amostragem dos eventos passados representam um espaço de decisão atemporal
- Ambientes de decisão episódica ou instantânea – problema é resolvido por decisão única, complexa ou não

Ambiente estocástico e decisão sequencial

- Ambientes estocásticos → a amostragem pode prever com probabilidade P a reação do meio – incerteza



43

Ambiente estocástico e decisão sequencial

- O agente deve reavaliar o meio a cada decisão tomada
- A próxima decisão será baseada na percepção atual de um meio em mutação e não alcançará necessariamente seu objetivo
- Deve-se analisar também a eficiência da série de decisões tomadas para alcançar certo objetivo. Este problema foi enfrentado pelo matemático russo Andrei Markov

44

Modelo decisório de Markov

- As mudanças do meio tendem a ser gradativas
- Os resultados das ações tendem a aproximar-se do pretendido, estatisticamente

45

Modelo decisório de Markov

- MDP:
 - Após a ação, o agente analisa novamente o meio e traduz a eficácia mediante uma recompensa, positiva ou negativa
 - Ao longo de uma sequência de decisões, a somatória das recompensas recebidas fornecerá informações sobre a assertividade das decisões do agente

46

Conceito de utilidade e a solução de Bellman

- Em ambientes estocásticos, a relação entre entrada e saída não é unívoca. Um mesmo vetor pode ter mais de uma saída, com probabilidades de ocorrência diferentes
- A utilidade U de uma decisão pode ser julgada pela somatória das recompensas, ou:

$$U_h ([S_0, S_1, S_2, \dots]) = R(S_0) + R(S_1) + R(S_2) + \dots$$

47

Conceito de utilidade e a solução de Bellman

- Se for possível calcular a utilidade ótima, será possível determinar a melhor sequência de decisões (política)
- A equação de Bellman pode fornecer possíveis soluções para este problema de otimização

48

Ambientes de RL

- **O estudo do ambiente é crucial na definição das estratégias de enfrentamento do problema**
- **Deve-se também buscar uma parametrização de ambientes hipotéticos que permitam a simulação das funcionalidades do algoritmo**
 - **Exemplo: ambiente de Littmann**

49

Finalizando

50

- **Buscamos construir o conceito de IA, das abordagens e ferramentas existentes, descrevendo algumas das técnicas de treinamento. Estamos preparados para o aprofundamento no tema específico que nos ocupará em breve**

51