

## Aula 1

### Inteligência Artificial Aplicada - Machine Learning

Prof. Antonio Willian Sousa

## Conversa Inicial

- Surgimento da área de IA
- Aprendizagem de máquina e ciência de dados
- Dado, informação e atributo
- Tipos de aprendizagem
- Ferramentas necessárias

## Conceitos básicos

## Inteligência artificial

- A inteligência está relacionada com a nossa capacidade de raciocínio
- O que é inteligência?
- Uma pergunta lançada em 1950: uma máquina pode ser dotada de inteligência?

- Alan Turing
- Teste de Turing
  - Um entrevistador interage com uma entidade, sem conseguir vê-la
  - Passa a perguntar por escrito
  - Ao final da entrevista, lhe é pedido que identifique se é um humano ou uma máquina

### ■ Capacidades necessárias para ser aprovado (Russell, Selvig, 2013)

- Capacidade robótica
- Visão computacional
- Processamento de linguagem natural
- Representação do conhecimento
- Raciocínio automatizado
- Aprendizado de máquina

### Evolução da área

- Décadas de 1950-60
- Década de 1970
- Década de 1980
- De 1995 até hoje

### O que pode fazer?

- Detecção de spam
- Planejamentos logísticos
- Tradução automática de voz e texto
- Jogos de computador
- Reconhecimento de voz
- Identificação de trajetos para robôs
- Reconhecimento facial

### Uma área em expansão

- Área estabelecida
- Dados e modelos disponíveis
- Barateamento do armazenamento
- Barateamento do processamento
- Ubiquidade

### Machine Learning e Data Science

### A aprendizagem de máquina

- “Machine Learning é um campo de estudo que dá aos computadores a capacidade de aprender sem que tenham sido explicitamente programados para tal” (Arthur Lee Samuel)



- **Dados quando processados geram informação**
- **Exemplo: data de nascimento – 10 de julho de 1998, ano atual – 2020, idade 22 anos**

19

- **Informação – quando analisada, agregada e cruzada – gera conhecimento**
- **Exemplo: pessoa nascida em 10 de julho de 1998 + nacionalidade brasileira + idade 22 anos = direito ao voto**

20

### **Tipos de dados**

- **Dados podem ser agrupados em numéricos e categóricos**
- **Dados numéricos: quaisquer valores ou observações que possam ser mensurados (altura, peso, número de filhos e outros)**
- **Dados categóricos: dado que representa descritores (gênero, estado civil e outros)**

21

- **Dados numéricos**
  - **Discretos: não podem ser medidos, mas podem ser contados**
  - **Contínuos: não podem ser contados, mas podem ser medidos**

22

- **Dados categóricos**
  - **Nominais: valores discretos que não envolvem valor quantitativo e não possuem relação de ordem entre si (idiomas que uma pessoa fala)**
  - **Ordinais: valores discretos que possuem relação de ordem entre si (grau de instrução)**

23

### **Atributos e características**

- **Atributo: propriedade de um fenômeno ou entidade que pode ser mensurada**
- **Atributo pode ser dado ou informação**
- ***Attribute = feature***

24

### Atributos

- Posição 1: idade (em anos)
- Posição 2: nacionalidade (0 – brasil, 1 – outro)
- Posição 3: altura (em metros)
- Posição 4: peso (em quilos)
- Posição 5: sexo (0 – masculino, 1 – feminino)
- Posição 6: gosta de futebol (0 – não, 1 – sim)
- Posição 7: salário (em reais)

25

### Vetor de características

- Cliente: Marcel da Silva (homem brasileiro, 22 anos de idade, altura de 1,70 m, peso 75 kg, gosta de futebol e recebe R\$ 2.500,00 de salário)

| posição | 1  | 2 | 3    | 4  | 5 | 6 | 7        |
|---------|----|---|------|----|---|---|----------|
| dados   | 22 | 0 | 1,70 | 75 | 0 | 1 | 2.500,00 |


26

### Conjunto de vetor de características

|   | Idade | Nacionalidade | Altura | Peso | Sexo | Gosta de futebol | Salário |
|---|-------|---------------|--------|------|------|------------------|---------|
| 0 | 22    | 0             | 1,70   | 75   | 0    | 1                | 2500    |
| 1 | 52    | 1             | 1,75   | 80   | 0    | 1                | 2500    |
| 2 | 31    | 1             | 1,50   | 65   | 1    | 1                | 4500    |
| 3 | 65    | 1             | 1,95   | 86   | 0    | 0                | 6500    |
| 4 | 17    | 0             | 1,81   | 95   | 0    | 1                | 1500    |
| 5 | 54    | 0             | 1,65   | 80   | 1    | 0                | 3500    |
| 6 | 30    | 0             | 1,90   | 105  | 1    | 1                | 1200    |
| 7 | 25    | 1             | 1,85   | 65   | 1    | 1                | 2245    |
| 8 | 49    | 0             | 1,71   | 75   | 0    | 0                | 25000   |
| 9 | 26    | 1             | 1,81   | 80   | 1    | 1                | 8000    |

27

### Separar e categorizar os dados



28

### Tipos de aprendizagem

- Métodos supervisionados ou preditivos
- Métodos não supervisionados ou descritivos
- Métodos semissupervisionados
- Métodos de aprendizagem por reforço

29

30

## Aprendizagem supervisionada

- Os dados fornecidos incluem exemplos indicando a solução desejada
- O conjunto de dados é composto de instâncias
- Cada instância é identificada por um rótulo/classe

31

## Detecção de spam – atributos

| POSICÃO | ATRIBUTO                                                      | VALORES POSSÍVEIS         |
|---------|---------------------------------------------------------------|---------------------------|
| 1       | ID da Mensagem                                                | 00001 - 10000             |
| 2       | Remetente conhecido?                                          | 0 - não, 1 - sim          |
| 3       | Idioma                                                        | 0 - Português, 1 - Outros |
| 4       | Palavras como herança, prêmio ou pagamento aparecem no texto? | 0 - não, 1 - sim          |
| 5       | Quantidade de erros gramaticais?                              | 0 - 1000                  |
| 6       | Quantidade de vezes que seu nome aparece no texto?            | 0 - 1000                  |
| 7       | Mensagem tem assinatura?                                      | 0 - não, 1 - sim          |
| 8       | Classe/Rótulo                                                 | 0 - spam, 1 - não-spam    |

32

## Detecção de spam – vetores de características

|             |    | ATRIBUTOS (1-7) |   |   |    |   |   |   | CLASSE       |
|-------------|----|-----------------|---|---|----|---|---|---|--------------|
| mensagem 01 | 01 | 0               | 1 | 1 | 10 | 0 | 0 | 0 | 0 (spam)     |
| mensagem 02 | 02 | 0               | 1 | 1 | 5  | 0 | 0 | 0 | 0 (spam)     |
| mensagem 03 | 03 | 0               | 0 | 1 | 19 | 0 | 0 | 0 | 0 (spam)     |
| mensagem 04 | 04 | 1               | 0 | 0 | 0  | 1 | 1 | 1 | 1 (não-spam) |
| mensagem 05 | 05 | 1               | 0 | 0 | 1  | 2 | 1 | 1 | 1 (não-spam) |

33

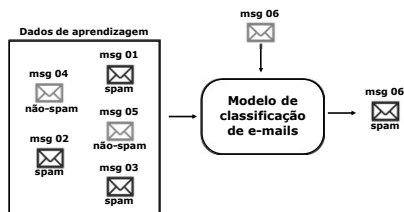
## Detecção de spam – nova instância

- Possui os mesmos atributos das instâncias usadas na aprendizagem
- Exceto a indicação de classe

|             |    | ATRIBUTOS (1-7) |   |   |    |   |   |   | CLASSE |
|-------------|----|-----------------|---|---|----|---|---|---|--------|
| mensagem 06 | 06 | 0               | 1 | 1 | 20 | 0 | 0 | ? | ?      |

34

## Detecção de spam usando Machine Learning



35

## Aprendizagem não supervisionada

- Não em informação de rótulo/classe
- Tenta aprender sozinho
- Busca aprender relações entre os dados

36


## Dados não rotulados

### ■ Não traz indicação de classe

|   | id | Idade | Gosta de esportes | Gosta de ler | Gosta de filmes | Código município | Sexo |
|---|----|-------|-------------------|--------------|-----------------|------------------|------|
| 0 | 1  | 22    | 0                 | 0            | 1               | 4106902          | 1    |
| 1 | 2  | 18    | 1                 | 1            | 1               | 4105508          | 0    |
| 2 | 3  | 40    | 0                 | 1            | 1               | 4106902          | 1    |
| 3 | 4  | 35    | 0                 | 1            | 1               | 4105508          | 1    |
| 4 | 5  | 26    | 0                 | 0            | 1               | 4106902          | 0    |

## Dados não rotulados

### ■ Tenta aprender formas de agrupar



## Ferramentas necessárias


## Ferramentas do profissional

- Linguagem de programação
- Tratamento de manipulação de dados
- Processamento numérico
- Visualização de dados
- Algoritmos de aprendizagem de máquina

## Linguagem de programação

- Python é interpretada
- Python é orientado a objetos
- Python é portátil
- Python é escalável
- Python possui biblioteca para quase tudo

- Bibliotecas do Python
  - Pandas: manipulação de dados
  - NumPy: cálculo computacional
  - Matplotlib: visualização de dados
  - Scikit-Learn: aprendizagem de máquina



43