

Aula 2

Inteligência Artificial Aplicada - Machine Learning

Prof. Antonio Willian Sousa

1

Conversa Inicial

2

- Intercâmbio de dados
- Processamento numérico
- Manipulação de dados
- Visualização de dados
- Bases de dados de aprendizagem

3

Formatos de intercâmbio de dados

4

Armazenamento de dados de aprendizagem

- Arquivos texto puro
- Arquivos de planilha eletrônica
- Bases de dados estruturadas
- Bases de dados não estruturadas
- Dados multimídia
- Arquivos serializados (binários)

5

Arquivos CSV

- Comma-Separated Value
 - Ex.: "22","0","1,70","75"
- Tab-Separated Value
 - Ex.: 22 0 1,7075
- Outros separadores podem ser usados

6

idade, nacionalidade, altura, peso, sexo, gosta de futebol, salario

```

22, 0, 1.7, 75, 0, 1, 2500
52, 1, 1.75, 80, 0, 1, 2500
31, 1, 1.5, 65, 1, 1, 4500
65, 1, 1.95, 86, 0, 0, 6500
17, 0, 1.81, 95, 0, 1, 1500
54, 0, 1.65, 80, 1, 0, 3500
30, 0, 1.9, 105, 1, 1, 1200
25, 1, 1.85, 65, 1, 1, 2245
49, 0, 1.71, 75, 0, 0, 25000
26, 1, 1.81, 80, 1, 1, 8000

```

7

Arquivos JSON

- JavaScript Object Notation
- Inspirado em JavaScript
- Legível para humanos, fácil para máquinas
- Facilmente associado a estruturas de dados

8

```

[{"nome": "Marcel da Silva", "idade": 22,
  "nacionalidade": "brasileiro", "altura": 1.70,
  "peso": 75, "sexo": "masculino",
  "gosta de futebol?": true, "salario": 2500},

 {"nome": "Ruan del Silva", "idade": 52,
  "nacionalidade": "mexicano", "altura": 1.75,
  "peso": 80, "sexo": "masculino",
  "gosta de futebol?": true, "salario": 2500}]

```

9

Serialização → JSON → desserialização

Python (serialização)	→ JSON →	Python (desserialização)
dict	object	dict
list, tuple	array	list
str	string	str
int, long, float	number	int, float
True, False	true, false	True, False
None	null	None

10

Além do CSV e JSON

```

<?xml version="1.0" ?>
<cliente>
  <campo name="Nome" tipo="str">Marcel da Silva</campo>
  <campo name="Idade" tipo="int">22</campo>
  <campo name="Nacionalidade" tipo="str">brasileiro</campo>
  <campo name="Altura" tipo="float">1.70</campo>
  <campo name="Peso" tipo="float">75</campo>
  <campo name="Sexo" tipo="str">masculino</campo>
  <campo name="Gosta de Futebol?" tipo="bool">True</campo>
  <campo name="Salario" tipo="float">2500</campo>
</cliente>

```

11

Processamento numérico

12

- Aprendizagem de máquina, além de computação, envolve muito cálculo matemático
- Cálculo e álgebra linear aplicados

13

Biblioteca NumPy

- Computação científica de alta *performance* no Python
- Não é nativa
- Principal objeto *ndarray*

14

Arrays NumPy

- Podem ser construídos a partir de listas e tuplas
- Identificados pelo seu formato
- Os dados são de um único tipo
- A biblioteca tem seus tipos próprios

15

Vectorization e broadcasting

```
import numpy as np
cliente_01 = np.array([22,0,1.70,75,0,1,2500])
todos_clientes = np.array([[52,1,1.75,80,0,1,2500],
                             [31,1,1.50,65,1,1,4500],
                             [65,1,1.95,86,0,0,6500],
                             [17,0,1.81,95,0,1,1500],
                             [54,0,1.65,80,1,0,3500],
                             ])

# Vectorization e broadcasting
array_comparacao = array_todos - vetor_cli_01
```

16

```
[[ 30.  1.  0.05  5.  0.  0.  0. ]
 [  9.  1. -0.2 -10.  1.  0. 2000. ]
 [ 43.  1.  0.25 11.  0. -1. 4000. ]
 [-5.  0.  0.11 20.  0.  0. -1000. ]
 [ 32.  0. -0.05  5.  1. -1. 1000. ]
 [  8.  0.  0.2  30.  1.  0. -1300. ]
 [  3.  1.  0.15 -10.  1.  0. -255. ]
 [ 27.  0.  0.01  0.  0. -1. 22500. ]
 [  4.  1.  0.11  5.  1.  0. 5500. ]]
```

17

Filtragem de dados

```
idx_salarios_menores = [ idx for idx,vec in
                        enumerate(array_comparacao)
                        if vec[-1] < 0]

todos_clientes[idx_salarios_menores]

[[ [-5.  0.  0.11 20.  0.  0. -1000. ]
 [  8.  0.  0.2  30.  1.  0. -1300. ]
 [  3.  1.  0.15 -10.  1.  0. -255. ]]
```

18

Outras bibliotecas

- Scikit-Learn
- TensorFlow
- PyTorch

19

Manipulando dados tabulares

20

Biblioteca Pandas

- Lida com dados de tipos diferentes
- Carrega dados de diferentes fontes
- Filtra, separa, agrupa e ordena
- Facilmente integrável com NumPy e Scikit-Learn

21

DataFrame Pandas

- Principal estrutura
- Lembra uma planilha eletrônica

	idade	nacionalidade	altura	peso	sexo	gosta de futebol	salário
Ana	22	Brasileiro	1,70	75,0	Feminino	True	2500
Beto	52	Estrangeiro	1,75	80,0	Masculino	True	2500
Bia	31	Estrangeiro	1,50	65,0	Feminino	True	4500
Carlos	65	Estrangeiro	1,95	86,0	Masculino	False	6500
Carol	17	Brasileiro	1,81	95,0	Feminino	True	1500

22

Criação de um DataFrame

TIPO DE DADO	COMPORTAMENTO
Dicionário de listas e tuplas	Cada objeto iterável dentro do dicionário se torna uma coluna, e a chave se torna o rótulo da coluna
Dicionário de dicionários	Cada dicionário se torna uma coluna, e as chaves dos dicionários internos se tornam os rótulos das linhas
Lista de dicionários, lista ou tuplas	Cada item se torna uma linha do DataFrame
Outro DataFrame	Cria um DataFrame igual ou com novos índices, se estes forem passados
Array NumPy	Cria um DataFrame de forma semelhante a quando passamos uma lista de listas

23

```
import pandas as pd

dados_clientes = {"idade": [22, 52, 31, 65, 17],
                  "nacionalidade": ["brasileiro", "estrangeiro",
                                    "estrangeiro", "estrangeiro",
                                    "brasileiro"],
                  "altura": [1.7, 1.75, 1.5, 1.95, 1.81],
                  "peso": [75.0, 80.0, 65.0, 86.0, 95.0],
                  "sexo": ["feminino", "masculino", "feminino",
                           "masculino", "feminino"],
                  "gosta de futebol": [True, True, True,
                                       False, True],
                  "salario": [2500, 2500, 4500, 6500, 1500]}

df_clientes = pd.DataFrame(data=dados_clientes,
                           index=["Ana", "Beto", "Bia", "Carlos", "Carol"])
```

24

Operações no DataFrame

- Selecione apenas uma coluna

```
df_clientes["idade"]
```

```
Ana    22
```

```
Beto   52
```

```
Bia    31
```

```
Carlos 65
```

```
Carol  17
```

```
Name: idade, dtype: int64
```

25

- Selecione apenas uma linha

```
df_clientes.loc["Ana"]
```

```
idade    22
```

```
nacionalidade brasileiro
```

```
altura    1.7
```

```
peso      75
```

```
sexo      feminino
```

```
gosta de futebol  True
```

```
salario    2500
```

```
Name: Ana, dtype: object
```

26

- Filtre todas as pessoas com idade maior que 30 anos e exiba apenas determinadas colunas

```
df_filtro = df_clientes.loc[:,["idade","sexo","salario"]]
```

```
df_filtro[df_filtro.idade > 30]
```

```
idade  sexo  salario
```

```
Bia    31    feminino  4500
```

```
Carlos 65    masculino  6500
```

Visualização de dados

28

- A visualização traz *insights* sobre os dados
- Ajuda a entender melhor
- Permite perceber relações
- Maneira condensada de comunicar

Biblioteca Matplotlib


- Diferentes tipos de visualizações
- Exporta para vários tipos de arquivos (pdf, jpeg, png, svg e outros)
- Integrável com NumPy e Pandas

29

30

	nome	idade	nacionalidade	altura	peso	sexo	gosta de futebol	salário
0	Aldo	22	0	1,70	75	0	1	2500
1	Beto	52	1	1,75	80	0	1	2500
2	Bia	31	1	1,50	65	1	1	4500
3	Carlos	65	1	1,95	86	0	0	6500
4	Diego	17	0	1,81	95	0	1	1500
5	Daina	54	0	1,65	80	1	0	3500
6	Carol	30	0	1,90	105	1	1	1200
7	Fabia	25	1	1,85	65	1	1	2245
8	Felix	49	0	1,71	75	0	0	25000
9	Gala	26	1	1,81	80	1	1	8000

31



32

Outras bibliotecas

- Seaborn
- Plotly
- Bokeh
- E muitas outras

33

Datasets

34

- Distribuídos em CSV e JSON
- Responsáveis pela aprendizagem
- Composto de instâncias
- A qualidade do seu modelo de aprendizagem será tão boa quanto forem os seus dados

35

- **Dataset**
 - **Instância:** registro ou linha de dados
 - **Atributos:** cada elemento descritor de uma instância
 - **Instâncias e atributos lembram** vetores de características
 - **Scikit-Learn:** aprendizagem de máquina

36

Dados do *dataset*

- Dados numéricos: quantitativos
- Dados categóricos: descritores não numéricos
- Dados de séries temporais: numéricos coletados
- Em intervalos de tempo consistentes
- Dados textuais: palavras, frases, parágrafos etc.

Onde obter *datasets*

- Dataset Search do Google
- Microsoft Research Open Data
- Open Data on AWS da Amazon
- UCI Machine Learning Repository
- Em diversos *sites*, portais e universidades

37

38

Características importantes

- Tipo de tarefa: classificação, regressão, agrupamento ou outro tipo
- Tipos dos atributos: categórico, numérico, misto
- Tipos de dados: multivariado, univariado, sequencial, série temporal, texto ou outros
- Quantidade de atributos e instâncias
- Formato dos dados

Datasets clássicos

- Iris Flower: 150 instâncias, 3 classes
- Boston House Pricing: 506 instâncias, preços
- Wine Quality: 4.898 instâncias, nota
- MNIST: 60 mil instâncias, 10 classes
- ImageNet: 14 milhões de instâncias, 20 mil categorias

39

40

Iris Dataset

- 150 instâncias, 3 classes, 4 atributos
- *Dataset* balanceado

	sepal length	sepal width	petal length	petal width	class	class_number
0	5.1	3.5	1.4	0.2	Iris-setosa	0
1	4.9	3.0	1.4	0.2	Iris-setosa	0
2	4.7	3.2	1.3	0.2	Iris-setosa	0
3	4.6	3.1	1.5	0.2	Iris-setosa	0
4	5.0	3.6	1.4	0.2	Iris-setosa	0
...	...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	Iris-virginica	2
146	6.3	2.5	5.0	1.9	Iris-virginica	2
147	6.5	3.0	5.2	2.0	Iris-virginica	2
148	6.2	3.4	5.4	2.3	Iris-virginica	2
149	5.9	3.0	5.1	1.8	Iris-virginica	2

Entendendo melhor os dados

Dataframe pandas contendo dataset
df_irisdata.describe()

	sepal length	sepal width	petal length	petal width	class_number
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.054000	3.758667	1.198667	1.000000
std	0.828066	0.433594	1.764420	0.763161	0.819232
min	4.300000	2.000000	1.000000	0.100000	0.000000
25%	5.100000	2.800000	1.600000	0.300000	0.000000
50%	5.800000	3.000000	4.350000	1.300000	1.000000
75%	6.400000	3.300000	5.100000	1.800000	2.000000
max	7.900000	4.400000	6.900000	2.500000	2.000000

41

42

Dividindo os dados

```
import numpy as np
from sklearn import datasets
from sklearn.model_selection import
train_test_split

iris_X, iris_y =
datasets.load_iris(return_X_y=True)
X_train,X_test,y_train,y_test =
train_test_split(iris_X, iris_y, random_state=0)
```

43

- Notação X (características), y (classes/rótulos)
- Treino – 75%/testes – 25%
- Dados podem fornecer capacidade de generalização

44