

Aula 4

Inteligência Artificial Aplicada - Machine Learning

Prof. Antonio Willian Sousa

Conversa Inicial

- Classificador bayesiano
- Usando modelo bayesiano
- Regressão linear e logística
- Usando modelos de regressão
- Classificação baseada em vizinhança

Classificador Bayesiano

- Sistemas antispam
- Classificador probabilístico
- Naive Bayes
- Baseado no Teorema de Bayes
- Desconsidera as relações entre atributos

Teorema de Bayes

- Qual a probabilidade de A ocorrer se B ocorreu ?
- $P(A | B)$: probabilidade a posteriori
 - ✓ Aquilo que se deseja descobrir
- $P(B | A)$: probabilidade de B dado A
- $P(A)$: probabilidade a priori
- $P(B)$: probabilidade marginal

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

Classificador bayesiano

- Qual a probabilidade de uma instância ser da classe y ?
 - $P(y \mid x_1, \dots, x_j)$: probabilidade a posteriori
 - y : classe ou categoria
 - $x_1, \dots, x_j$: atributos da instância
- $$P(y \mid x_1, \dots, x_j) = \frac{P(x_1, \dots, x_j \mid y)P(y)}{P(x_1, \dots, x_j)}$$
- $P(x_1, \dots, x_j \mid y) = P(x_1 \mid y) \times \dots \times P(x_j \mid y)$
 - $P(y)$: se sabe pois o método é supervisionado
 - $P(x_1, \dots, x_j) = P(x_1) \times \dots \times P(x_j)$

$$P(y | x_1, \dots, x_j) = \frac{P(x_1, \dots, x_j | y)P(y)}{P(x_1, \dots, x_j)}$$

- Qual a probabilidade de um cliente gostar de futebol dado que é homem e brasileiro?

- $P(\text{homem} \mid \text{gosta de futebol}) = 57\%$
 - $P(\text{brasileiro} \mid \text{gosta de futebol}) = 57\%$
 - $P(\text{gosta de futebol}) = 70\%$
 - $P(\text{homem}) = 60\%$
 - $P(\text{brasileiro}) = 45\%$
- | Gosta futebol | Masculino | Feminino | Brasil |
|---------------|-----------|----------|--------|
| SIM | 40 | 30 | 46 |
| NÃO | 20 | 15 | 25 |

Gosta futebol	Masculino	Feminino	Brasileiro	Estrangeiro	Total
Sim	40	30	40	30	70
NÃO	20	10	5	25	30
Total	60	40	45	55	

- 👉 $P(\text{gosta de futebol} \mid \text{homem, brasileiro}) = (0,57 \times 0,57 \times 0,70) / (0,60 \times 0,45) = 0,8423$

Usando classificador Bayesiano

Diferentes implementações

- **Gaussian Naive Bayes**
- **Multinomial Naive Bayes**
- **Bernoulli Naive Bayes**

Dataset

[illegible]

Classificação

- Tarefa
 - Dados os atributos de um carro, prever o seu fabricante

Dataset de automóveis	
Total de registros do dataset	11913
Tamanho do conjunto de treino	9427
Tamanho do conjunto de testes	2357
Quantidade de características	14
Quantidade de classes	48

```
import pandas as pd
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split

# Lê o dataset de carros
carros = pd.read_csv("carros.csv")

# Seleciona apenas as colunas necessárias
X = carros.loc[:, 'ano':'preco_venda'].to_numpy()
y = carros['label'].to_numpy()
```


Divide o conjunto em treinamento e teste, na proporção 80-20

```
X_treino, X_teste, y_treino, y_teste =
train_test_split(X, y, test_size=0.20)
```

Executa a definição e treinamento do modelo

```
gnb = GaussianNB()
gnb.fit(X_treino, y_treino)
```

Qualidade da predição




classe	precision	recall	f1-score
Acura	1.00	1.00	1.00
Aston Martin	1.00	1.00	1.00
Audi	1.00	1.00	1.00
BMW	1.00	1.00	1.00
Bentley	1.00	1.00	1.00
Buick	1.00	1.00	1.00
Cadillac	1.00	1.00	1.00
Chevrolet	1.00	1.00	1.00
...	...	...	...
Subaru	1.00	1.00	1.00
Suzuki	1.00	1.00	1.00
Toyota	1.00	1.00	1.00
Volkswagen	0.99	0.95	0.97
Volvo	0.87	0.96	0.92

- Classificações erradas de um total de 2.357 instâncias: 11

Classificação do modelo do automóvel

- Tarefa
 - Dados os atributos de um carro, prever o seu modelo
- Classificações erradas: 177
- Precisão (média): 0,925
- Recall (média): 0,912
- F1-Score (média): 0,904

Dataset de automóveis	
Total de registros do dataset	11913
Tamanho do conjunto de treino	9427
Tamanho do conjunto de testes	1845
Quantidade de características	14
Quantidade de classes	381



```
from sklearn.calibration import CalibratedClassifierCV

# Calibração isotônica
isotonic = CalibratedClassifierCV(gnb, cv=4,
                                method='isotonic')
isotonic.fit(X_treino, y_treino)
```



CALIBRADO	SEM CALIBRAÇÃO
Erros: 119	Erros: 177
Precisão (média): 0,945	Precisão (média): 0,925
Recall (média): 0,932	Recall (média): 0,912
F1-Score (média): 0,935	F1-Score (média): 0,904

Regressão linear e logística

Regressão linear

- Investiga relação entre variáveis
- Inferir valores
- Indica quais variáveis contribuem para os valores finais
- Indica se pares de variáveis estão relacionados

- Y: variável dependente
- X: variável independente
- β_0, β_1 : valores buscados



$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$


$$Y = \beta_0 + \beta_1 X$$

Regressão logística

- Predição categórica
- Prediz a probabilidade de a variável independente assumir determinado valor
- Duas classes: regressão logística binomial
- Muitas classes: regressão logística multinomial

$$\log\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X$$

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$



- Função sigmoide
- Variável independente entre 0 e 1
- Não lida bem com número elevado de atributos

Usando modelos de regressão

Regressão logística

ano	combustivel	hp	cilindros	tip_transmissao	tracao	num_portas	categoria	tanque	veloc	km_por_l_entrada	km_por_l_cidade	popul_cidade	preco_venda	valor
2011	7	200.0	6.0	3	3	2.0	68	0	4	28	19	3916	40650	1
2011	7	200.0	6.0	3	3	2.0	65	0	5	28	20	3916	36330	1
2011	7	230.0	6.0	3	3	2.0	68	0	5	28	18	3916	29490	1
2011	7	230.0	6.0	3	3	2.0	64	0	4	28	18	3916	34000	1
2012	7	230.0	6.0	3	3	2.0	68	0	5	28	18	3916	31200	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2017	3	355.0	8.0	0	3	4.0	49	1	3	23	16	549	57315	0
2017	3	355.0	8.0	0	0	4.0	49	1	3	22	16	549	51390	0
2017	5	428.0	8.0	0	3	4.0	70	1	3	22	15	549	65965	0
2017	3	355.0	8.0	0	0	4.0	49	1	3	22	16	549	60315	0
2017	3	355.0	8.0	0	3	4.0	49	1	3	23	16	549	48530	0

- Dada uma instância de automóvel, predir se ele é popular ou não

Categorização de atributos

- Representa categorias ou tipos
- Cada tipo possui um código
- Não há hierarquia entre os valores

Atributo: tipo_transmissão	
CÓDIGO	CATEGORIA
0	AUTOMATICO
1	AUTOMATIZADO
2	DIRECT_DRIVE
3	MANUAL
4	DESCONHECIDO

Treinamento do modelo

```
# Lê o dataset de carros
df_carros =
pd.read_csv("carros_modelos_categorical.csv"
)
X = carros.iloc[:, :-1].to_numpy()
y = carros.iloc[:, -1].to_numpy()
```

Divide o conjunto em treinamento e teste, na proporção 80-20

```
X_treino, X_teste, y_treino, y_teste =
train_test_split(X, y, test_size=0.20, stratify=y,
random_state=123,
shuffle=True)
```

Classificacao Regressao Logistica


```
clf_logistica =
linear_model.LogisticRegression(C=1e5)
clf_logistica.fit(X_treino, y_treino)
y_pred_logistica = clf_logistica.predict(X_teste)
```

Resultados regressão logística

	precision	recall	f1-score
não popular	0.62	0.97	0.76
popular	0.60	0.08	0.14

Um pouco melhor que uma escolha aleatória

Baixo recall, alta taxa de falsos negativos



Codificação one-hot encoder

Atributo: tipo_transmissão (tt)				
tt_automatico	tt_automizado	tt_direct_drive	tt_manual	tt_desconhecido
1	0	0	0	0
0	1	0	0	0
0	0	1	0	0
0	0	0	1	0
0	0	0	0	1

- Cada categoria se torna um novo atributo

Resultados regressão logística

	precision	recall	f1-score
não popular	0.70	0.74	0.72
popular	0.55	0.50	0.53

- Resultados foram melhores, mas ainda é possível melhorar



Regressão linear

- Predição de valores contínuos
- Alguns atributos são difíceis de discretizar
- Atributos como preço de venda
- Processo supervisionado

Treinamento do modelo

```
# Lê o dataset de carros
carros =
pd.read_csv("carros_modelos_categorical.csv")

# Seleciona apenas as colunas necessárias
X = carros.loc[:,
'combustivel':'popularidade'].to_numpy()
y = carros['preco_venda'].to_numpy()
```

```
# Divide o conjunto em treinamento e teste, na
proporção 80-20
```


```
X_treino, X_teste, y_treino, y_teste =
train_test_split(X, y, test_size=0.20)
```

```
# Classificacao Regressão Linear
```

```
ols =
linear_model.LinearRegression(normalize=True)
ols.fit(X_treino, y_treino.reshape((-1, 1)))
```

```
y_pred_ols = ols.predict(X_teste)
```

Resultados regressão logística




Coefficiente de determinação: 0.60
Quadrado da média dos erros:
675861464.37

- Buscar reduzir erro quadrático médio
- Buscar aumentar coeficiente de determinação
- Não há certo e errado

Classificação baseada em vizinhança

kNN


- K-Nearest Neighbors
- Baseado na vizinhança
- Instâncias próximas tendem a serem parecidas
- k instâncias mais próximas votam
- Qual valor de k escolher?



Valores de k


- Valores muito baixos
 - Geram underfitting
- Valores muito altos
 - Geram overfitting

Underfitting




- Baixa capacidade de generalização
- Não consegue aprender a partir dos dados
- Desempenho ruim já nos dados de treino

Overfitting



- Baixa capacidade de generalização
- Aprende demais os dados de treino
- Desempenho excelente nos dados de treino

Good Fit



- Modelo intermediário
- Capacidade de generalizar
- Busca equilíbrio entre variância e bias

Treinamento kNN

```
# Lê o dataset de carros
carros =
pd.read_csv("carros_modelos_categorical.csv"
)
X = carros.iloc[:, :-1].to_numpy()
y = carros.iloc[:, -1].to_numpy()
X = StandardScaler().fit_transform(X)
```

Divide o conjunto em treinamento e teste, na proporção 80-20

```
X_treino, X_teste, y_treino, y_teste =
train_test_split(X, y, test_size=0.20)
```

Treina o modelo

```
knn5 =
KNeighborsClassifier(algorithm='ball_tree')
knn5.fit(X_treino, y_treino)
y_pred_5 = knn5.predict(X_teste)
```

Resultados regressão logística

Usando Regressão Logística			
	precision	recall	f1-score
não popular	0.70	0.74	0.72
popular	0.55	0.50	0.53

Usando kNN com k = 5			
	precision	recall	f1-score
não popular	0.89	0.89	0.89
popular	0.84	0.83	0.84



kNN

- Simple de utilizar
- Treinamento pode ser demorado
- Escolher o valor ideal de k pode se tornar uma tarefa difícil
- Pode ser utilizado para tarefas de regressão