

Aula 5

Inteligência Artificial Aplicada - Machine Learning

Prof. Antonio Willian Sousa

1

Conversa Inicial

2

- Algoritmo k-means
- Medidas de distância
- Usando k-means
- Agrupamento hierárquico
- Outros métodos não supervisionados

3

Algoritmo k-means

4

- Método não supervisionado
- Processo iterativo
- Particionamento dos dados em k-grupos
- Escolha dos agrupamentos pela distância


5

Conjunto de dados


Fonte: Sousa, 2020

	Idade	Peso	Altura	Última Compra	Código Município	Sexo	Total Comprado	Salário
0	52.0	37.0	124.0	194.0	6.0	0.0	455.0	10391.11
1	57.0	57.0	117.0	97.0	7.0	1.0	1516.0	13315.56
2	34.0	89.0	188.0	549.0	12.0	1.0	4849.0	2453.33
3	55.0	48.0	120.0	194.0	4.0	1.0	304.0	14568.89
4	52.0	52.0	102.0	162.0	6.0	1.0	531.0	16240.00
...	...	...	...	...	...	...	...	...
995	28.0	66.0	172.0	291.0	13.0	1.0	3637.0	1617.78
996	34.0	57.0	171.0	468.0	12.0	1.0	4167.0	3915.56
997	32.0	25.0	110.0	678.0	17.0	1.0	6061.0	5168.89
998	56.0	55.0	124.0	49.0	4.0	1.0	379.0	16240.00
999	23.0	31.0	122.0	404.0	12.0	1.0	7652.0	8928.89


6




7



8



9



10



11



12

Questionamentos fundamentais

- Como escolher o k?
- Qual medida de distância usar?


13

Como escolher o valor de k?

- Método do cotovelo
 - Inércia
 - Distorção

14

Método do cotovelo



Fonte: Sousa, 2020


15

Medidas de distância

16

Distância euclidiana

- Comumente utilizada em problemas de aprendizagem de máquina



Fonte: Sousa, 2020

$$p = (p_0, p_1), q = (q_0, q_1)$$

$$\text{dist}(p, q) = \sqrt{(q_0 - p_0)^2 + (q_1 - p_1)^2}$$

$$p = (p_0, p_1, \dots, p_{n-1})$$

$$q = (q_0, q_1, \dots, q_{n-1})$$

$$\text{dist}(p, q) = \sqrt{\sum_{i=0}^{n-1} (q_i - p_i)^2}$$


17

Distância Manhattan

- O caminho entre os pontos não é direto
- O deslocamento é feito um eixo por vez
- Distância do táxi
- Distância dos quarteirões

18

- Pode substituir a distância euclidiana em altas dimensões




$$\text{dist}(p, q) = \sum_{l=0}^{n-1} |q_l - p_l|$$

Fonte: Sousa, 2020

19

Distância cosseno

- Baseada na similaridade cosseno



$$\text{similaridade} = \cos \theta$$

$$\cos \theta = \frac{p \cdot q}{\|p\| \cdot \|q\|} = \frac{\sum_{l=1}^n p_l q_l}{\sqrt{\sum_{l=1}^n p_l^2} \sqrt{\sum_{l=1}^n q_l^2}}$$


$$\text{DistânciaCosseno}(p, q) = 1 - \text{similaridade}(p, q)$$

Fonte: Sousa, 2020

20

Distância de Mahalanobis

- Avalia em relação à distribuição dos dados
- Uso da matriz de covariância inversa permite definir o grau de independência entre os atributos



Fonte: Sousa, 2020

21

Distância de Hamming

- Mede distância entre seqüências de bits

from scipy.spatial import distance

distance.hamming([0,0,1,0,0,0,1], [0,0,0,0,0,0,1])

Valor da distância é 1

	tipo_transmitido_1	tipo_transmitido_2	tipo_transmitido_3	tipo_transmitido_4	traces_1	traces_2	traces_3
0	0	0	1	0	0	0	1
1	0	0	1	0	0	0	1
2	0	0	1	0	0	0	1
3	0	0	1	0	0	0	1
4	0	0	1	0	0	0	1
5	0	0	1	0	0	0	1
...	...	...	...	...	...	...	...
11746	0	0	0	0	0	0	1
11747	0	0	0	0	0	0	0
11748	0	0	0	0	0	0	1
11749	0	0	0	0	0	0	0
11750	0	0	0	0	0	0	1

Fonte: Sousa, 2020

22

Usando o k-means

23

Dataset

Fonte: Sousa, 2020

	Idade	Peso	Altura	Última Compra	Código Município	Sexo	Total Comprado	Salário
0	52.0	37.0	124.0	194.0	6.0	0.0	455.0	10391.11
1	57.0	57.0	117.0	97.0	7.0	1.0	1516.0	13315.56
2	34.0	89.0	188.0	549.0	12.0	1.0	4849.0	2453.33
3	55.0	48.0	120.0	194.0	4.0	1.0	304.0	14568.89
4	52.0	52.0	102.0	162.0	6.0	1.0	531.0	16240.00
...	...	...	...	...	...	...	...	...
995	28.0	66.0	172.0	291.0	13.0	1.0	3637.0	1617.78
996	34.0	57.0	171.0	468.0	12.0	1.0	4167.0	3915.56
997	32.0	25.0	110.0	678.0	17.0	1.0	6061.0	5168.89
998	56.0	55.0	124.0	49.0	4.0	1.0	379.0	16240.00
999	23.0	31.0	122.0	404.0	12.0	1.0	7652.0	8928.89

24

Criação e execução do modelo

```
from sklearn.cluster import KMeans
import pandas as pd
import numpy as np

# Lê o conjunto de dados
X = pd.read_csv("dados_clientes_compras.csv").to_numpy()


# Executa k-means
modelo_kmeans = KMeans(n_clusters=3).fit(X)
modelo_kmeans.fit(X)

# Realiza a predição
y_pred = modelo_kmeans.predict(X)
```


25

Agrupamentos/clusters

Predição



Real



26

Visualizando os agrupamentos

- Por pares ou trios de atributos
- É difícil perceber relações
- Solução é reduzir as n-dimensões
- Principal Component Analysis (PCA)**

27

PCA

Selecionar apenas uma coluna

	Idade	Peso	Altura	Última Compra	Código Município	Sexo	Total Comprado	Salário
0	52.0	57.0	124.0	194.0	6.0	0.0	455.0	10391.11
1	57.0	57.0	117.0	97.0	7.0	1.0	1516.0	13315.56
2	34.0	89.0	188.0	549.0	12.0	1.0	4849.0	2453.33
3	55.0	48.0	120.0	194.0	4.0	1.0	304.0	14568.89
4	52.0	52.0	162.0	162.0	6.0	1.0	531.0	16240.00
...	...	...	...	...	...	...	...	...
995	28.0	66.0	172.0	291.0	13.0	1.0	3637.0	1617.78
996	34.0	57.0	171.0	468.0	12.0	1.0	4167.0	3915.56
997	32.0	25.0	110.0	678.0	17.0	1.0	6061.0	5168.89
998	56.0	55.0	124.0	49.0	4.0	1.0	379.0	16240.00
999	23.0	31.0	122.0	404.0	12.0	1.0	7652.0	8928.89




PCA

	PC1	PC2	Cluster
0	0.254961	1.594636	2
1	1.693504	-1.607076	1
2	-2.123146	-1.517009	0
3	0.536663	0.336852	2
4	-2.101821	-0.610420	2
...	...	...	...
995	-1.001324	-0.628468	0
996	-2.803128	-0.514234	0
997	-2.474521	-0.602548	0
998	2.413928	-0.148478	1
999	1.941450	-1.120015	1

28

Visualizando com PCA



- Necessita normalização
- É uma dica de como podem ser os agrupamentos reais


29

Entendendo os agrupamentos

- O resultado dos agrupamentos foi bom?
- Coeficiente de Silhouette pode nos dizer
- O que cada agrupamento significa?
- Plotagem paralela dos atributos pode nos dizer

30

Plotagem paralela



- Mostra informações sobre os agrupamentos
- Permite comparação

31

Agrupamento hierárquico


32

Processo de agrupamento

- Inicia com n grupos contendo uma instância
- Agrupa os grupos mais próximos
- Recalcula distância dos grupos e repete
- Termina com um agrupamento com n instâncias

33

Dendrograma



- Visualização em árvore
- Possível escolher k agrupamentos
- Interpretável

34

Utilização agrupamento hierárquico

- Necessita normalização
- Necessita de uma métrica de distância
- Como calcular as distâncias
- Não necessita definir k

35

Outros métodos não supervisionados

36

Outros algoritmos

- ▀ K-medoides
- ▀ K-means mini-batches
- ▀ Inicializações diferentes
 - Exemplo: k-means++

37

DBSCAN

- ▀ *Density-Based Spatial Clustering of Applications with Noise*
- ▀ Baseado em densidade
- ▀ Não necessita definir k
- ▀ Resistente a outliers

38

BIRCH

- ▀ *Balanced Iterative Reducing and Clustering Using Hierarchies*
- ▀ Execução rápida
- ▀ Utiliza uma estrutura em árvore específica

39

Algoritmo de maximização da esperança

- ▀ Funciona de forma generativa
- ▀ Cria modelos para os agrupamentos
- ▀ Avalia em qual modelo/agrupamento as instâncias se adequam melhor

40